白酒财报 RAG 知识库 —— 一页结论

系统：12 家 A 股白酒上市公司 84 份年报/半年报（13,584 页 → 39,702 个文本块），本地解析建索引，向量 + BM25 混合召回、跨公司逐家检索，本地 4B 模型带出处作答，每个数字可回溯到原文块与页码；全程离线。**成绩**：可对外的是**第三批新题（金标先冻结，含 2 道跨公司全景题）10 道答对 4 道**；开发阶段那几轮用的都是练过的题，只作回归参考。

1. 第一轮：3 → 7 → 4 → 7，两轮掉坑两轮爬起来

阶段	题集	正确率	一句话读法
基线	v1 十题	3/10	指标准确、口径定向、全局问法、表格读行、跨公司覆盖——五处一起漏
五步优化后	同一批题	7/10	指标定向 → 报告期区分 → 全局路由 → 净利润规则 → 生成侧，每步只改一个模块
换全新题	v2 十题	4/10	换题就露馅：练出来的规则迁移不过去
通用结构兜底后	v2 同一批题	7/10	不再硬编码科目名，改用「表格段 / 千分位 / 科目形状 / 主表头 / 受限与拆分」五种结构信号认行

一句话：**② 是在原题上练出来了，③ 是换题露馅，④ 是补上泛化能力后重新站住。**

2. 第二轮：先把「练出来的分」和「真会」分开

批次	身份	分数	能不能对外
第一批	开发题	3/10 → 7/10	不能：只说明改过的地方有没有退步
第二批	原检验题，已被反向调参污染	4/10 → 7/10	不能：看过错题再改代码，就不再是新题
第三批	**新题（检验题，含 2 道全景题）**	**4/10**	**能**：金标逐条抄自原文，跑系统之前做哈希并盖章（`冻结金标.py --verify` 可校验）

老师所说的	做了什么
12 家公司 84 份报告	84 份 PDF 入库，每家 7 期；39,702 块全部带公司、年份、报告类型、页码
两批题区分开发题与新题	新增第三批，三批身份在逐题记录里分开写；第三批没有「修复前」，试跑过就不叫新题
补完整逐题记录	30 道题逐条：金标、出处（报告+页码+块号）、召回位次、答案用到哪几块、修复前后对比
优先修单位	表头被切块后不再「看不出单位」：相邻块声明 → 同句自带单位 → **量级校验**（超 10 万亿当场改成「元」并写明理由）
优先修负号	变化率照旧核方向词；新增**金额负号**：原文 −1,640,352.63 被抄成正数时自动补回；嘴上还说「净流入」的只报警不改
优先修指标别名	口径判定改成**最长匹配**（「营业总成本」5 字 > 「营业成本」4 字 → 判不符），并只按数字所在那一小句判，避免一句话里两个科目互相干扰
冻结新题金标	哈希 + 时间戳，三批题库 `--verify` 全部一致；整批重出后重新盖章（10-21 14:13）
全景按公司取证	12 家逐家扫「管理层讨论与分析」全节，出覆盖地图；第三批现在有 2 道真全景题
召回与答案分别评价	逐题记录每题两栏：「证据找没找到」与「找到之后读没读对」

3. 分开记之后看到的东西（第三批 · 重建版）

失败类型	题号	表现
证据落在错年份	1、6、8	问句带「比 2024 年……」，程序取最后一个年份 → 证据全在 2024 年报上，只能说「材料不足」。书拿错了，不是读不懂
找对了但单位错	4	−195,138,847.45 元写成「万元」，差 1 万倍。量级不离谱，程序只提示不替它改
全景取数、结论错	9	12 家营业收入**全部取对**，但「谁降得最多」答成口子窖 −22.89%，实为泸州老窖 −36.35%
全景叙述、整段被否	10	12 家的块都召回了，归纳型回答没法逐句挂到单独一块，引用校验全否，最终输出「材料不足」

全景题：**12 家每一家**都写了行业问题和应对措施，所以答不全不是语料问题，是**取样方式**问题——一次 Top-K 只能端上来三四家。逐家扫完后「行业深度调整」10/12、「存量竞争」10/12、「动销下降」10/12，「渠道库存」7/12、「价格体系」6/12；应对措施里渠道、品牌、消费者培育、数字化都是 12/12。**拉开差别的是 10/12 和 6/12 那一栏，不是满格那一栏。**

4. 仍然错在哪、还有哪些做不到

- 没答对的 6 题（5 题答错、1 题部分正确）责任分得清：**1、6、8 是召回层**（年份识别取「最后一个年份」），**4 是生成层**（单位），**9、10 是全景层**（结论、汇总）。
- 年份识别这个 bug 已经定位到 `代码/检索引擎.py` 的 `detect_year()`，**本轮没改**：改完必须另出题库 4 才能测，否则这批题又变成「练过的题」。
- 母公司 / 合并两张表都写着「营业成本」，检查程序**不会自动报警**，只能靠「答案用到哪几块」的页码人工比对。
- 答案回溯 ≠ 取对行：能证明「这个数来自这一块」，证明不了「取的是正确的那一行」。
- 单位只敢改「离谱」的：换算成 16.9 万亿的当场改；1.95 万亿这种量级不离谱的，只提示不改——第 4 题因此仍算错。
- 判分尺子也修过一处：问句没问的变化幅度不再算必答（旧规则 2/10 → 新规则 5/10 → 人工复核第 9 题后 **4/10**），三个数都写在 `第14步` 里。

> 一句话：这一轮没有把分数刷高，而是把**分数的来历**弄清楚了——四轮开发各自说明什么、三批题谁算数、召回与答案分开评价、全景按公司取证，再把单位、负号、指标别名这三类「数字抄对了却算错」的毛病从「检查不出来」改成「能当场指出来，量级明显离谱的当场改掉并写明理由」。**4/10 不好看，但每道错题都能指到具体页码和具体原因。**