

白酒财报 RAG 知识库 —— 一页结论

系统：12 家 A 股白酒上市公司 84 份年报/半年报（13,584 页 → 39,702 个文本块）本地解析建索引； 向量 + BM25 混合召回；本地 4B 模型带出处作答；每个数字可回溯到原文块、公司、年份、报告类型与页码。

实验链路：v1 基线 3/10 → v1 优化后 7/10 → v2 全新题 4/10 → v2 通用兜底后 7/10

1. 第一版主要失败在哪

基线只答对 3 题，失败集中在检索定向，不是模型不会说话：

失败	表现
指标/口径定向缺失	问毛利率答营业收入；问「经销商已打款未确认收入」映射不到「合同负债」
年报 / 半年报混召回	同一年两种报告并存时取到半年报的数当年度数，同比口径直接错
全局问法没展开	「哪些白酒公司...」只召回 6/12 家，结论必然不完整
表格读不出目标行	宽表里取到「分渠道小计行」而非合并口径（−1.08% vs 真值 −1.21%）
跨公司覆盖不均	点到名的几家里，有的公司只召到 1 块且是无关块

共同点：答案所需的原文其实在库里，只是没被召回来；召错行比召不到更危险。

2. 做了哪些改进（五步串行，每步只改一个模块）

- 指标定向（代码/指标规则.py）：营收、合同负债、毛利率、净利润、产销量 5 组指标做同义扩展 + 加权 + 定向配额（保证目标块至少占一半席位——加权救不回排几千名的块）。
 - 报告期区分（代码/检索引擎.py）：明确说「半年报」走硬过滤；只说年份时优先年报、不足时软加权，避免零召回。
 - 全局路由：三级正则识别「全部白酒公司 / 12 家 / 哪些公司」，展开为 12 家逐家各召，再轮转合并。
 - 净利润规则：补「归母净利润 / 净利润」口径，跨公司题每家用同一口径参数。
 - 生成侧：先按表头定位目标行再读数；单位照抄原文；跨公司先逐家列值与单位再比较；禁止自算合计。
- v1 正确率 3/10 → 7/10。

3. 哪些改进真正泛化（换题后依然成立）

- 泛化 报告期识别：v2 中 4 道涉及年份的题全部落对；Q3 只给「2025 年」而该公司年报与半年报都有 ROE，仍正确落到年报。
- 泛化 全局 12 家覆盖：v2 两道全局题均为 12 家 × 3 块均匀分布，coverage_ok=True，「只召 6 家」未复发。
- 泛化 单位与格式：v1 乱补「万元」的病没复发；「% 与百分点」「元/股」「元」都写对。
- 泛化 失败时不编造：v2 三道检索失败题全部诚实答「材料不足」，零幻觉。

泛化的是路由层（找哪家、找哪一期、找哪张表），不是指标层。

4. 哪些地方出现过拟合

过拟合 指标定向严重依赖 代码/指标规则.py 的 5 条白名单规则。v2 三道失败题（存货、货币资金、销售费用）全部在规则外，全部召回不来；而 v1 里「跨公司对、全局对」靠的正是营收、毛利率、净利润——全在白名单内，换指标后跨公司 0/2、全局 0/2。

结论：v1 的 7/10 里真本事与「背题」约各占一半。系统学会的是「这几类指标怎么做题」，不是「怎么定位一个陌生会计科目」。净泛化提升只有 +10pt（30%→40%），而 v1 内部提升是 +40pt。

5. 最后一轮：为什么用通用结构信号代替逐科目硬编码

继续给存货、货币资金、销售费用各写一条规则只是把白名单加长，过拟合不会消失——下一个没写过的科目照样崩。所以最后一轮改问一个更一般的问题：「财报里，什么样的文本块才装着科目数据？」答案与科目无关，只与报表结构有关。新增 代码/科目兜底.py（仅当五组规则都没命中时启用）：

通用信号	系数	作用
不是表格块（叙述段）	×0.55	压掉「原因说明 / 会计政策」
没有任何千分位金额	×0.35	压掉「4Q、销售费用 单位：元」这类空表头
科目行形状（汉字科目名 + 分隔符 + 千分位金额）	×2.4	捞起真正带数字的行
主表表头（主要会计数据 / 三大报表 / 资产构成表）	×2.2	优先主表，压附注明细
受限 / 抵押 / 子公司 / 关联方 / 会计政策	×0.5	压掉非目标口径

科目词典（约 80 条通用会计科目）只做「写法 → 标准科目名」的归一，条目之间零权重差异；跨公司题仍在每家公司内部独立执行同一套逻辑。

效果：规则外科目的真值块 0/3 → 3/3，其中 Q6「压在仓库里还没卖出去的那些货」压根没识别出科目名，靠实义词 + 结构信号照样捞中；v2 正确率 4/10 → 7/10，且对规则内题目零干扰（Q10 召回块序列与优化前完全一致）。这轮的收获不是多对 3 道题，而是证明了「用结构信号替代逐科目硬编码」这条路走得通。

6. 老师反馈后的补强（第 09—10 步）

- 分层抽样 复查发现分层抽样已经在做（跨公司题逐家检索、再轮转合并），硬伤是每家只分到 2 块——覆盖到 12/12 但材料太薄：问「12 家现金流前三」时，泸州老窖那 2 块里没有现金流数据被整个漏掉，第三名答错。把总量上限 24 → 48，每家 3 块，并对「召到的块里没有『目标科目名 + 金额』」的公司二次补召。
- 同义词扩展 原先只有精确子串匹配，词典外的口语说法抓瞎：「账上现金」召到现金分红、「卖酒收到的现金」召到每 10 股派息。新增 代码/查询改写.py：正则把口语行一到标准科目名（账上现金→货币资金、打款未发货→合同负债、压仓库的货→存货、赊账→应收账款...），再补同族近义词作为第三路 BM25。四类全局问法里「仍无目标科目的公司」全部清零。
- 校验器误判 末段排名 / 汇总句复述前文已引过证的数字、自己不再带 [n]，被判「材料不足」→答案全对却自相矛盾地追加「不予采信」。改为：先在「本回答引用过的全部块」里找，找到即继承前文出处；两处都找不到才报材料不足，防幻觉底线不变（编造数字仍被拦截）。

回归：v2 仍 7/10（数值正确 10/10），Q10 问题句 8 → 0、可追溯数 42/61 → 52/52；v1 十题 7/10 无退化。

7. 最终仍存在的局限

局限	表现	归因
单位判断	Q8 三家销售费用数值与结论全对，单位却写成「万元」（原文为元），模型还自辩「按财报惯例统一处理」	生成侧
正负号判断	Q10 把 +7.07%、+7.80% 判成「下滑」，真下滑 4 家全中却多报 2 家；同一份答案两次排序还不一致	生成侧
数字写法归一化	Q2 原文「每 10 股派 50 元」而模型写「50.00元」；Q9 原文 31,136,736,628.58 元而模型写「311.37亿元」——补零与四舍五入到亿元后无法反查，数值正确仍被判「未定位」	校验器
可追溯 ≠ 取对行	校验器只能证明「数字来自这块」，不能证明「取的是正确的那一行」。第 09 步加厚材料 + 二次补召后 Q9 已答对，但机制上仍无保证	校验器边界

这四处都在生成侧与校验器，不在检索环节；按要求停止开发，未做修改，作为已知局限保留。

一句话总结

先测后改、每题留痕，才看得清「7/10」里有多少是真本事：路由层（找哪家 / 哪一期 / 哪张表）的改进真的泛化了，指标层的白名单规则只是把题背会了；最后一轮用「科目无关的通用结构信号」兜底，才把泛化能力补回来（未知指标召回 0/3 → 3/3）， 剩余缺陷全部集中在单位判断、正负号判断、数字写法归一化这三处生成侧 / 校验器问题上。